SMART AGRICULTURE PIPELINE : PREDIKSI PRODUKTIVITAS PANEN UNTUK MEWUJUDKAN ZERO HUNGER

PEMROSESAN INFRASTRUKTUR DATA

Dosen Pengampu :

Eko Sakti Pramukantoro, S.Kom., M.Kom., Ph.D.

Disusun Oleh :

Rezky Auliasarie	245150300111014
Alexander Agung Widhi P.	245150300111054
Muhammad Raihan Bakhtiar	245150301111010
Zeyra Rahma Alivia	245150301111016
Muhammad Naufal M.R.	245150307111006
Chelsea Kurnia Sandy	245150307111053

FAKULTAS ILMU KOMPUTER

UNIVERSITAS BRAWIJAYA

I. ABSTRAK

Ketahanan pangan merupakan isu strategis yang memerlukan dukungan sistem informasi berbasis data untuk memahami keterkaitan antara faktor lingkungan dan produktivitas pertanian. Proyek ini mengembangkan sebuah pipeline data yang mengintegrasikan data pertanian dari BPS serta data cuaca dari BMKG untuk membangun model prediksi hasil panen berbasis regresi sederhana. Proses Extract, Transform, Load (ETL) digunakan untuk menyatukan data dengan perbedaan format, struktur, dan tingkat granularitas sehingga menghasilkan dataset yang bersih dan konsisten. Setelah itu, model regresi digunakan untuk menganalisis pengaruh variabel cuaca seperti curah hujan, suhu, dan kelembaban terhadap produktivitas tanaman pangan.

Hasil prediksi tersebut divisualisasikan melalui dashboard interaktif berbasis Streamlit agar dapat digunakan untuk kepentingan dalam memantau tren produktivitas dan risiko pertanian. Sistem yang dikembangkan memberikan gambaran awal mengenai bagaimana data cuaca mempengaruhi hasil panen dan dapat dijadikan dasar untuk perencanaan kebijakan maupun strategi pertanian yang lebih adaptif. Proyek ini menjadi langkah awal dalam membangun Smart Agriculture Pipeline sebagai upaya mendukung pencapaian tujuan Zero Hunger dan ketahanan pangan nasional.

Kata Kunci : Ketahanan pangan, ETL, Prediksi panen, Cuaca, Regresi, Streamlit.

II. LATAR BELAKANG

Ketahanan pangan merupakan salah satu tantangan strategis yang terus mendapat perhatian di tingkat nasional maupun global. Indonesia, sebagai negara agraris dengan keragaman agroekologi yang luas, menghadapi tekanan ganda: meningkatnya kebutuhan pangan akibat pertumbuhan penduduk dan perubahan pola iklim yang memengaruhi produktivitas pertanian. Variabilitas iklim berimplikasi langsung terhadap kinerja produksi komoditas pangan pokok, khususnya padi. Untuk menjaga stabilitas produksi dan merumuskan kebijakan yang tepat, diperlukan kemampuan analitis yang memadukan data statistik pertanian dengan data iklim lingkungan secara sistematis.

Sumber data pertanian resmi, seperti publikasi BPS, menyediakan indikator penting seperti luas panen, produksi total, dan produktivitas (ton per hektar) pada skala administratif provinsi atau kabupaten. Namun demikian, data BPS umumnya disajikan pada frekuensi tahunan dan bersifat agregat; data ini memberikan gambaran makro yang penting tetapi memiliki keterbatasan ketika digunakan untuk memahami dinamika temporal dan spasial yang disebabkan oleh kondisi cuaca lokal. Sebaliknya, dataset cuaca dan iklim yang dikelola oleh BMKG menyediakan informasi observasi pada granularitas yang lebih tinggi (harian atau per jam) dari stasiun cuaca yang tersebar. Integrasi kedua jenis data ini berpotensi menghasilkan wawasan yang jauh lebih kaya: data iklim yang berskala tinggi dapat menjelaskan variabilitas antar-tahun dan antar-wilayah yang tidak tampak pada data agregat tahunan semata.

Namun, upaya integrasi ini menghadapi beberapa tantangan teknis dan metodologis non-trivial. Perbedaan tingkat granularitas (BPS: tahunan/administratif vs BMKG: harian/stasiun), variasi format file, heterogenitas atribut, serta ketidakmerataan distribusi stasiun pengamatan menyebabkan kebutuhan untuk merancang pipeline ETL (Extract–Transform–Load) yang andal. Tahap ekstraksi harus mampu mengumpulkan data statis BPS dan data dinamik BMKG secara repeatable; tahap transformasi harus menyelesaikan isu missing values, perbedaan skala temporal, penghapusan anomali, dan transformasi fitur (feature engineering) yang relevan secara agronomis; tahap pemuatan harus menghasilkan basis data terstruktur yang memungkinkan kueri analitik dan pengambilan sampel untuk pemodelan. Tanpa proses

preprocessing yang sistematis, analisis lebih lanjut berisiko menghasilkan kesimpulan yang bias atau tidak dapat direproduksi.

Di samping tantangan teknis pengolahan data, terdapat kebutuhan metodologis untuk memilih pendekatan pemodelan yang sesuai dengan tujuan aplikasi. Model yang terlalu kompleks (mis. model deep learning) mungkin memberikan akurasi prediksi yang lebih tinggi, tetapi sering kali mengorbankan kemampuan interpretasi yang penting untuk pengambil kebijakan di sektor pertanian. Sebaliknya, model berbasis regresi linear multivariat memberikan interpretabilitas koefisien yang berguna untuk memahami arah dan besar efek variabel iklim terhadap produktivitas; sehingga model ini cocok sebagai baseline analitis dan alat bantu kebijakan awal. Oleh karena itu, rancangan penelitian ini menempatkan regresi linear berganda sebagai titik awal untuk mengidentifikasi variabel kunci dan besaran pengaruhnya sekaligus membuka jalur bagi pengembangan model non-linear atau spasial pada tahap lanjutan.

Pertimbangan spasial juga kritikal: provinsi atau kabupaten yang berdekatan cenderung memiliki pola iklim dan praktik agronomi yang mirip, sehingga analisis harus mempertimbangkan kemungkinan autokorelasi spasial dan heterogenitas regional. Penggunaan agregasi stasiun BMKG ke level wilayah administratif harus dilakukan dengan metode pemetaan spasial yang mempertimbangkan jarak dan representativitas stasiun terhadap kawasan pertanian. Selain itu, variabel tambahan seperti karakteristik tanah (pH, kandungan bahan organik, tekstur), varietas padi, dan praktik budidaya (irigasi, pemupukan) merupakan faktor non-iklim yang dapat memperkaya model dan mengurangi residual error; absennya data tersebut menjadi sumber keterbatasan yang perlu dikomunikasikan secara eksplisit dalam laporan analisis.

Di tingkat operasional, hasil analitik perlu disajikan dalam bentuk yang dapat diakses dan dimanfaatkan pemangku kepentingan: petani, penyuluh, perencana provinsi, hingga pembuat kebijakan nasional. Dashboard interaktif yang menampilkan metrik kunci, sebaran produktivitas, heatmap korelasi, analisis what-if, serta alat prediksi berbasis input skenario menjadi media yang efektif untuk mentransfer temuan analitis menjadi keputusan praktis. Integrasi model ke dalam dashboard juga memerlukan perhatian pada pipeline deployable agar sistem berubah dari bukti konsep menjadi alat operasional.

Berdasarkan konteks tersebut, proyek ini mengembangkan sebuah Smart Agriculture Pipeline yang menggabungkan proses ETL, feature engineering agronomis (mis. drought index, interaksi hujan×suhu), pemodelan prediktif awal berbasis regresi linear berganda, serta visualisasi melalui dashboard interaktif. Pendekatan ini bertujuan tidak hanya untuk menghasilkan prediksi produktivitas yang dapat dipercaya, tetapi juga untuk menyediakan reasoning teknis yang jelas tentang faktor-faktor penyebab perubahan produktivitas sehingga dapat mendukung strategi pengelolaan air, adaptasi varietas, dan intervensi kebijakan pada skala provinsi maupun nasional.

III. RUMUSAN MASALAH

1. Bagaimana proses integrasi data pertanian (BPS) dan data cuaca (BMKG) melalui pipeline ETL dapat mendukung pengembangan model prediksi hasil panen yang akurat?

2. Bagaimana model prediksi berbasis regresi sederhana mampu menggambarkan hubungan antara variabel cuaca, kondisi tanah, dan produktivitas pertanian?

3. Bagaimana pemanfaatan dashboard prediksi dapat membantu pemangku kepentingan dalam pengambilan keputusan terkait ketahanan pangan?

IV. TUJUAN PROYEK

1. Membangun pipeline ETL yang mengintegrasikan data pertanian dan cuaca secara sistematis dan terstandarisasi.
2. Mengembangkan model prediksi hasil panen berbasis regresi sederhana untuk memperkirakan produktivitas berdasarkan data iklim, cuaca, dan lahan.
3. Merancang dashboard informasi yang menampilkan hasil prediksi guna mendukung perumusan kebijakan dan strategi peningkatan ketahanan pangan.

V. DATASET YANG DIGUNAKAN

Dataset	Sumber	Informasi	Format	Link
BPS Pertanian	BPS	Luas Panen, Produksi, dan Produktivitas Padi Menurut Provinsi, 2024	CSV/JSON	https://www.bps.go.id/id/statistics-table/2/MTQ5OCMy/luas-panen-produksi-dan-produktivitas-padi-menurut-provinsi.html
Data Online BMKG	BMKG	Data Iklim Harian Menurut Provinsi, 2024	CSV	https://dataonline.bmkg.go.id/dataonline-home

VI. ARSITEKTUR SISTEM / PIPELINE DATA

Pipeline data untuk proyek ini dirancang sebagai sistem ETL Batch yang bertujuan untuk mengintegrasikan data statistik pertanian heterogen dengan data cuaca historis. Tujuan utamanya adalah untuk menciptakan satu dataset terstruktur yang siap digunakan untuk pemodelan prediktif.

Arsitektur sistem yang diusulkan akan mengikuti alur pemrosesan data sebagai berikut:

1. **Extract (Ingest)**
    a. Data Pertanian (Batch): Data historis produksi, produktivitas, dan luas panen dari BPS Pertanian akan diekstraksi. Data ini berbentuk file statis (CSV/Excel) yang diunduh langsung dari portal masing-masing.
    b. Data Cuaca (Batch): Data cuaca historis (suhu, curah hujan, kelembaban) akan ditarik dari data online BMKG. Data ini berbentuk file statis (CSV) yang diunduh dari situs BMKG.

2. **Transform**
    a. Ini adalah fase paling kritis. Data yang diekstraksi memiliki granularitas yang berbeda (data BPS bersifat tahunan/bulanan per wilayah, data BMKG bersifat bulanan per stasiun).
    b. Proses transformasi utama adalah agregasi dan *feature engineering*. Data cuaca bulanan BMKG akan diagregasi menjadi fitur-fitur yang bermakna secara tahunan (misal: rata_rata_suhu_musim_tanam, total_curah_hujan_tahunan, jumlah_hari_panas_ekstrem).
    c. Data akan dibersihkan (*handling missing values*) dan di-transformasi.
    d. Data BPS dan BMKG yang sudah diagregasi akan digabungkan (*join*) berdasarkan kunci bersama, yaitu wilayah (misal: kode provinsi/kabupaten) dan waktu (tahun).
3. **Load (Store)**
    a. *Dataset* final yang telah bersih dan terstruktur akan dimuat ke dalam *database* relasional.
    b. Tool yang digunakan untuk menyimpan data terstruktur dan memfasilitasi kueri analitik adalah PostgreSQL.
4. **Analyze (Batch Model)**

    Sebuah *script* Python menggunakan Scikit-learn akan mengambil data dari *database* untuk melatih model "regresi sederhana" sesuai permintaan kasus.
5. **Visualize**

    Sebuah *dashboard* interaktif (diusulkan menggunakan Streamlit) akan terhubung ke *database* untuk menyajikan hasil prediksi dan *insight* faktor cuaca.



Gambar Flowchart ETL

Flowchart ini menjelaskan alur kerja sistem mulai dari pengambilan data hingga ditampilkan pada dashboard. Proses dimulai dengan Extract Data BPS, yaitu mengumpulkan data pertanian seperti luas panen, produksi, dan produktivitas dari portal BPS. Setelah itu, sistem melakukan Extract Data BMKG untuk mengambil data cuaca seperti suhu, curah hujan, kelembaban, dan hari hujan melalui situs BMKG.

Kedua data yang sudah diambil kemudian masuk ke tahap Transform Data, yaitu proses pembersihan dan pengolahan data. Pada tahap ini dilakukan penyesuaian format, perhitungan fitur tambahan, normalisasi, serta penggabungan data berdasarkan provinsi dan tahun. Hasilnya adalah dataset akhir yang siap dianalisis. Selanjutnya, data yang sudah bersih dimasukkan ke dalam Database melalui tahap Load, sehingga dapat disimpan secara terstruktur dan mudah diakses. Tahap terakhir adalah Dashboard Streamlit, yaitu sistem yang mengambil data dari database dan menampilkan grafik, tabel, atau indikator prediksi sehingga pengguna dapat melihat hubungan antara cuaca dan produktivitas pertanian. Alur ini memastikan data dari berbagai sumber diproses secara teratur dan konsisten sebelum digunakan untuk analisis dan visualisasi.

DEMO PIPELINE BERJALAN

Demo Pipeline.mp4

Rincian Flow Data

Tahap Pipeline	Data / Tools Digunakan	Fungsi Utama	Alasan Pemilihan Tools
1. Extract BPS	- CSV BPS 2024- pandas	Membaca dan membersihkan data produksi padi (luas panen, produksi, produktivitas)	Pandas sangat kuat untuk parsing CSV dan cleaning data tabular
2. Extract BMKG	CSV BMKG 2024- pandas, regex	Normalisasi nama provinsi, cleaning, dan perhitungan awal (hari hujan)	Regex membantu standar nama provinsi; pandas mempermudah manipulasi data
3. Cleaning & Standardization	pandas, numpy	Bersihkan nilai hilang, konsistenkan format provinsi, ubah tipe data	Stabil, cepat, dan mudah di-debug untuk dataset 30–40 baris
4. Feature Engineering	pandas, numpy	Membuat fitur baru: suhu_kategori, hujan_kategori, drought_index, interaction features, normalisasi	Mendukung operasi matematis dan transformasi data kompleks
5. Integrasi Dataset	pandas merge	Menggabungkan data BPS + BMKG berdasarkan (provinsi, tahun)	Merge di pandas sangat cocok untuk join kecil/terstruktur
6. Load ke Database	PostgreSQL, SQLAlchemy, psycopg2	Membuat tabel dan menyimpan data raw & processed ke DB	PostgreSQL stabil untuk analitik; SQLAlchemy mempermudah operasi CRUD

7. Modeling	scikit-learn (LinearRegression)	Melatih model prediksi produktivitas ton/ha	Model sederhana cocok untuk dataset 34–38 provinsi (low sample)
8. Evaluation	sklearn metrics, matplotlib	Mengukur MSE, RMSE, MAE, R^2 dan membuat visualisasi residu	Tools standar untuk analisis performa model
9. Saving Model	joblib	Menyimpan model ke file .pkl	Kompatibel dengan sklearn dan sangat ringan
10. Dashboard	Streamlit, Plotly, pandas	Menampilkan visualisasi, analisis provinsi, cuaca vs produktivitas, dan tool prediksi	Streamlit cepat dibuat, interaktif, mudah integrasi Python
11. Config Manager	YAML	Menyimpan kredensial DB	Aman, mudah dibaca, dapat diganti tanpa mengubah kode
12. Orchestration	Python subprocess (run_pipeline.py)	Menjalankan seluruh script pipeline secara berurutan	Sederhana untuk workflow linear dan modular

VII. METODOLOGI

Metodologi proyek ini dibagi menjadi empat tahapan utama yang mencerminkan alur *pipeline* data:

1. Akuisisi Data:
    a. Data BPS: Mengunduh *dataset* CSV dari portal resmi BPS (fokus pada data Tanaman Pangan, komoditas Padi, per Provinsi/Kabupaten)
    b. Data BMKG: mengunduh *dataset* CSV dari portal resmi BMKG yang berfokus pada temperatur minimum, temperatur maksimum, temperatur rata-rata, kelembapan rata-rata, curah hujan, lamanya penyinaran matahari, kecepatan angin maksimum, arah angin saat kecepatan maksimum, kecepatan angin rata-rata, dan arah angin terbanyak.

Akuisisi Data BPS (Static Batch Download)

tahun	provinsi	luas_panen_ha	produksi_ton	produktivitas_ton_per_ha
2024	ACEH	301196.35	1659966.28	5.511
2024	SUMATERA UTARA	419463.48	2204875.51	5.256
2024	SUMATERA BARAT	295278.98	1356467.93	4.593999999999999
2024	RIAU	56421.96	222055.71	3.936
2024	JAMBI	61625.68	281022.05	4.5600000000000005
2024	SUMATERA SELATAN	521092.21	2909411.67	5.583

2024	BENGKULU	55775.09	272848.55	4.892
2024	LAMPUNG	531715.12	2791347.53	5.25
2024	KEP. BANGKA BELITUNG	18202.56	77489.79	4.257
2024	KEP. RIAU	113.33	305.09	2.692
2024	DKI JAKARTA	498.31	2306.54	4.629
2024	JAWA BARAT	1475362.09	8626879.91	5.8469999999999995
2024	JAWA TENGAH	1554777.14	8891297.05	5.718999999999999
2024	DI YOGYAKARTA	96976.13	452831.77	4.67
2024	JAWA TIMUR	1616985.05	9270435.29	5.733
2024	BANTEN	299090.79	1550623.46	5.184
2024	BALI	103803.93	635473.35	6.122
2024	NUSA TENGGARA BARAT	281717.84	1453408.37	5.159000000000001
2024	NUSA TENGGARA TIMUR	168727.24	707792.54	4.195

2024	KALIMANTAN BARAT	247207.72	764784.15	3.0940000000000003
2024	KALIMANTAN TENGAH	111016.13	366146.82	3.2979999999999996
2024	KALIMANTAN SELATAN	246112.42	1029567.93	4.183
2024	KALIMANTAN TIMUR	63041.65	249642.9	3.96
2024	KALIMANTAN UTARA	8282.06	30079.77	3.632
2024	SULAWESI UTARA	59121.96	273134.94	4.62
2024	SULAWESI TENGAH	172606.22	761936.39	4.414
2024	SULAWESI SELATAN	951308.6	4818429.39	5.0649999999999995
2024	SULAWESI TENGGARA	129999.61	555836.08	4.276
2024	GORONTALO	46952.15	234862.88	5.002000000000001
2024	SULAWESI BARAT	63181.59	318876.59	5.047

2024	MALUKU	23947.35	91125.35	3.8049999999999997
2024	MALUKU UTARA	9366.71	31232.95	3.3340000000000005
2024	PAPUA BARAT	5121.13	20729.15	4.048
2024	PAPUA BARAT DAYA	363.87	988.64	2.717
2024	PAPUA	1068.57	4609.95	4.314
2024	PAPUA SELATAN	47168.57	217789.62	4.617
2024	PAPUA TENGAH	1436.12	6072.38	4.228
2024	PAPUA PEGUNUNGAN	9.66	42.38	4.387

Akuisisi Data BMKG (Static Batch Download)

TANGGAL	TN	TX	TAVG	Provinsi
01-01-2024	24,2	33	29,2	Aceh
01-01-2024	25,6	32,4	28,8	Bali
01-01-2024	24,7	32,1	30,2	Banten
01-01-2024	24,8	30,6	28,7	Bengkulu
01-01-2024	24,2	32,4	29,4	DI Yogyakarta
01-01-2024	24,2	32,2	29,8	DKI Jakarta
01-01-2024	24,1	-	29,3	Gorontalo
01-01-2024	24,8	28,1	26,7	Jambi
01-01-2024	23,6	31,3	27,5	Jawa Barat
01-01-2024	25,6	34	30,6	Jawa Tengah
01-01-2024	21,8	30,8	27,1	Jawa Timur
01-01-2024	24,5	32,4	29,9	Kalimantan Barat

01-01-2024	25,1	33	29,2	Kalimantan Selatan
01-01-2024	24,9	33	27,7	Kalimantan Tengah
01-01-2024	24,8	31,3	27,2	Kalimantan Timur
01-01-2024	25,6	30,4	27,1	Kalimantan Utara
01-01-2024	24,4	31,2	28,1	Kep. Bangka Belitung
01-01-2024	26,4	28,9	27,1	Kep. Riau
01-01-2024	23,4	32	28,7	Lampung
01-01-2024	25,6	-	29,9	Maluku
01-01-2024	23,4	34,9	28,5	Maluku Utara
01-01-2024	26,2	34,5	29,7	Nusa Tenggara Barat
01-01-2024	26	32,8	31,3	Nusa Tenggara Timur
01-01-2024	24	33	28,6	Papua
01-01-2024	24,4	33,5	29,3	Papua Barat

01-01-2024	23,9	31,1	27,7	Riau
01-01-2024	25,4	32,4	29,1	Sulawesi Barat
01-01-2024	26,1	31,8	28,6	Sulawesi Selatan
01-01-2024	23,6	33,2	28,7	Sulawesi Tengah
01-01-2024	24,8	35,2	32	Sulawesi Tenggara
01-01-2024	23,4	31,2	28,4	Sulawesi Utara
01-01-2024	23,8	33	28,4	Sumatera Barat
01-01-2024	25,8	31,8	29,4	Sumatera Selatan
01-01-2024	25,2	30,8	29	Sumatera Utara

2. Transformasi dan *Feature Engineering*:
    a. Proses ini akan menggunakan *library* Pandas di Python.
    b. Langkah-langkah utamanya meliputi:
        i. Pembersihan Data: Menangani nilai yang hilang (*missing values*) dengan metode imputasi (misal: *mean*, *median*) atau penghapusan baris/kolom.
        ii. Agregasi Temporal: Mengubah data cuaca bulanan BMKG menjadi fitur tahunan yang relevan

(data sudah di agregasi jadi 1 tahun)

Provinsi	TN	TX	TAVG	RH_AVG	RR	SS	FF_X	DDD_X	FF_AVG
SUMATERA SELATAN	25.5063360881543	60.7648351648352	29.2769230769231	79.0876712328767	1023.68438438438	1309.05789473684	2.628415300546645	159.991803278689	0.88797814207650 3
JAWA TIMUR	20.7524861878453	29.8901098901099	25.3944903581267	77.7988980716254	444.288405797101	5.5590027700831	4.1043956043956	156.414835164835	1.7417582417582 4
KALIMANTAN TENGAH	23.9193905817175	32.6517808219178	27.2524725274725	85.3780821917808	549.894166666667	4.95928338762215	4.60928961748634	186.597260273973	1.4125683060109 3
KALIMANTAN UTARA	24.8008219178082	32.8591780821918	27.9698630136986	84.3589041095891	621.1184375	4.49631901840491	5.60928961748634	124.385245901639	1.1065573770491 8
MALUKU UTARA	23.2827397260274	32.5372602739726	27.5547945205479	89.3589041095891	1151.19945205479	4.56904109589041	3.3879781420765	188.950684931507	0.7622950819672 13
PAPUA	23.9230136986301	31.987397260274	27.7556473829201	85.5179063360882	823.634177215191	4.61972602739726	2.7049180327868 9	152.210382513661	0.6530054644808 74

KALIMANTAN SELATAN	24.0645604395604	32.5641095890411	29.1169312169312	78.9153439153439	1051.17536656892	4.8454794520548	3.4672131147541	182.07650273224	1.9726775956284 2
SULAWESI SELATAN	24.8580821917808	31.8767759562842	28.4090410958904	81.5972602739726	861.759178082192	5.7260273972602 7	4.2103825136612	237.75956284153	1.8469945355191 3
SULAWESI TENGAH	24.08	32.3483870967742	27.8032258064516	83.1935483870968	2299.67096774194	4.0870967741935 5	4.3548387096774 2	58.387096774193 6	0.8387096774193 55
DI YOGYAKARTA	23.2162983425414	31.6734806629834	27.4183060109 29	78.4426229508197	330.598787878788	5.7506887052341 6	4.5476839237057 2	219.258855585831	2.0326975476839 2
KALIMANTAN TIMUR	24.1349030470914	32.801095890411	27.3852054794521	86.6109589041096	1637.81948424069	3.7372602739726	3.4535519125683 1	170.2465753424 66	0.6612021857923 5
PAPUA BARAT	23.5383561643836	31.8770491803279	27.7169863013699	84.4767123287671	453.862876254181	4.3197260273972 6	28.480874316939 9	167.0464480874 32	27.494535519125 7
SULAWESI UTARA	23.7195592286501	31.8671270718232	27.8457534246575	80.3315068493151	1019.96567164179	4.9961432506887 1	2.8852459016393 4	162.6164383561 64	1.1338797814207 7
JAWA BARAT	23.0884615384615	32.5593406593407	26.7621917808219	82.6082191780822	362.519277108434	5.4191780821917 8	7.7759562841530 1	208.7704918032 79	1.8961748633879 8
GORONTALO	23.5439093484419		29.3539682539683	75.5026455026455	1160.40749279539	4.5201657458563 5	2.1311475409836 1	166.9207650273 22	0.3633879781420 77
ACEH	23.5225895316804	33.2084699453552	28.5063013698630	76.5452054794521	1246.71643835616	5.6079452054794 5	4.2295081967213 1	203.9890710382 51	2.2404371584699 5
MALUKU	140.479178885631		28.1391780821918	84.6136986301370	661.448680351906	4.5047752808988 8	30.904371584699 5	190.1202185792 35	28.617486338797 8

SULAWESI BARAT	25.3986263736264	32.2386301369863	28.4043835616438	79.5972602739726	1112.2510989011	6.24986301369863	4.06830601092896	162.07650273224	2.0655737704918
SUMATERA UTARA	222.831161473088	32.8299168975069	28.9565934065934	80.1291208791209	1185.57177700348	32.4823691460055	4.31506849315069	129.254794520548	1.8027397260274
KALIMANTAN BARAT	24.8927777777778	31.8809392265193	28.48	83.1260273972603	655.232558139535	4.97823691460055	3.81693989071038	214.234972677596	1.7267759562841 5
DKI JAKARTA	26.7208333333333	32.7625344352617	29.3475138121547	78.6191780821918	673.834971098266	5.66961325966851	5.16666666666667	152.989071038251	2.0901639344262 3
JAWA BARAT	107.335890410959	33.3161202185792	29.1783561643836	78.0082191780822	781.933779264214	4.81589041095 89	4.08743169398907	154.016393442623	1.7404371584699 5
RIAU	23.675204359673	32.5114441416894	28.1656675749319	81.3297002724796	235.099150141643	4.67230320699709	2.49728260869565	169.460490463215	0.5407608695652 17
LAMPUNG	24.0989010989011	32.8742465753425	28.3465753424658	79.1671232876712	899.302298850575	4.94383561643836	2.39617486338798	164.956284153005	1.0737704918032 8
SULAWESI TENGGARA	23.6506849315069	32.5633333333333	28.0531506849315	82.1780821917808	1077.36246575342	4.43780821917808	2.41530054644809	179.51912568306	0.8114754098360 66
NUSA TENGGARA TIMUR	24.5465753424658	33.1534435261708	29.1556164383562	74.9369863013699	526.212540192926	7.36383561643836	5.00546448087432	208.087431693989	2.5409836065573 8
BENGKULU	24.8148351648352	32.1937158469945	28.5958904109589	82.4273972602739	889.820120120 12	6.11123287671233	4.48087431693989	216.475409836066	2.5901639344262 3
KEP. BANGKA BELITUNG	24.5571428571429	32.0934246575343	28.2545205479452	85.1863013698 63	624.166561514196	4.53506849315069	3.46994535519126	147.377049180328	1.5

JAMBI	24.364010989011	32.5991758241758	27.8101369863014	86.027397260274	1457.28217522659	4.38164383561644	2.50273224043716	186.065573770492	0.6748633879781 42
JAWA TENGAH	24.977808219178 1	33.4729508196721	29.2424657534247	74.613698630137	474.65467032967	6.4793956043956	5.16712328767123	229.226775956284	2.0109289617486 3
NUSA TENGGARA BARAT	24.102747252747 3	32.4775956284153	29.3698412698413	76.746031746031 8	591.59890109890 1	6.55123287671233	4.33060109289618	212.841530054645	2.1174863387978 1
SUMATERA BARAT	22.923463687150 8	31.9246537396122	26.9591160220995	84.668508287292 8	681.76317365269 5	4.50745856353591	2.78787878787879	204.710743801653	1.0633608815427
BALI	24.255371900826 4	31.4177595628415	28.8592592592593	79.989417989418	713.64065934065 9	6.38846153846154	5.07377049180328	154.808743169399	1.9426229508196 7
KEP. RIAU	25.683333333333 3	31.8562326869806	28.4019230769231	83.186301369863	1486.48882521 49	4.24033149171271	4.09016393442623	133.465753424658	1.4644808743169 4

iii. Integrasi Spasial: Memetakan data cuaca (dari stasiun BMKG) ke data pertanian (per provinsi). Ini akan dilakukan dengan mencari stasiun cuaca terdekat untuk setiap wilayah administrasi.

iv. Join Data: Menggabungkan kedua sumber data (BPS dan BMKG) menjadi satu DataFrame utama.

3. Pemodelan Prediktif:
    a. Sesuai dokumen kasus, model yang akan diimplementasikan adalah "regresi sederhana". Ini akan diimplementasikan sebagai Regresi Linear Berganda (*Multiple Linear Regression*) menggunakan Scikit-learn.
    b. Variabel Target (Y): Produktivitas Panen (dari data BPS).
    c. Variabel Fitur (X): Agregat Cuaca (dari BMKG, misal: total_curah_hujan), Data Pertanian Lain (misal: Luas Panen).

d. Data akan dibagi menjadi data latih (80%) dan data uji (20%) untuk mengevaluasi performa model menggunakan metrik seperti R-squared dan RMSE.

4. Visualisasi Hasil:
    a. Hasil prediksi, performa model, dan *insight* faktor cuaca akan divisualisasikan menggunakan Streamlit. *Dashboard* akan dirancang untuk menampilkan peta produktivitas nasional dan analisis *what-if* sederhana berdasarkan faktor cuaca.

VIII. HASIL DAN ANALISIS

tahun	provinsi	luas_panen_ha	produksi_ton	produktivitas_ton_per_ha	…	…	….
2024	ACEH	301196.35	1659966.28	5.511			
2024	BALI	103803.93	635473.35	6.122			
2024	BANTEN	299090.79	1550623.46	5.184			

Kode : https://github.com/BangNopall/smart-agriculture-pipeline

Hasil dashboard : http://54.179.70.136/

1. Analisis Variabel Pertanian dan Cuaca

a. Luas Panen

Jawa Timur, Jawa Tengah, dan Jawa Barat memiliki luas panen terbesar; Papua Barat, Maluku Utara, dan Papua memiliki luas panen paling kecil. Perbedaan ini menunjukkan bahwa pusat produksi pangan masih terkonsentrasi di wilayah tertentu, sementara daerah lain belum sepenuhnya mampu memanfaatkan potensi lahannya.

b. Produksi (Ton)

Provinsi dengan luas panen besar juga menghasilkan produksi tertinggi, terutama di Jawa. Hal ini mengisyaratkan bahwa produktivitas nasional masih bergantung pada beberapa wilayah utama sehingga ketahanan pangan ikut tergantung pada stabilitas daerah tersebut.

c. Produktivitas (Ton/Ha)

Bali, Jawa Barat, dan Jawa Timur memiliki produktivitas tertinggi; Kep. Riau, Kalbar, dan Maluku Utara terendah. Produktivitas yang tidak berbanding lurus dengan luas lahan menunjukkan bahwa kualitas tanah, pengelolaan, dan kondisi iklim berperan lebih besar daripada sekadar luasan area.

d. Suhu Rata-rata

Suhu berkisar antara 25,3°C–29,4°C; provinsi yang lebih panas cenderung memiliki produktivitas lebih rendah. Ini menyiratkan bahwa tekanan panas mulai menjadi faktor nyata yang menurunkan performa tanaman meski kenaikan suhu terlihat kecil.

e. Curah Hujan

Curah hujan sangat bervariasi dari sangat rendah hingga sangat tinggi antarprovinsi. Variasi ini menunjukkan bahwa ketersediaan air tidak merata, sehingga daerah dengan hujan rendah berpotensi memerlukan sistem irigasi yang lebih baik untuk menjaga produktivitas.

f. Kelembaban

Kelembaban relatif stabil di seluruh provinsi. Stabilitas ini mengindikasikan bahwa kelembaban bukanlah faktor pembeda utama antar wilayah dalam konteks produktivitas padi.

g. Hari Hujan

Jumlah hari hujan berkisar 50–200 hari per tahun, namun tidak selalu mencerminkan produktivitas. Hal ini menandakan bahwa intensitas hujan lebih penting daripada frekuensi, dan beberapa wilayah mungkin mengalami hujan ringan tapi tidak efektif bagi tanaman.

2. Analisis Fitur Rekayasa

a. Drought Index

Nilai rendah menandakan risiko kekeringan tinggi, terlihat pada NTT, Riau, Jabar, dan Papua. Ini menunjukkan bahwa kebutuhan air tidak terpenuhi merata, dan beberapa wilayah sangat bergantung pada sistem irigasi untuk menjaga produksi.

b. suhu_kategori

Mayoritas provinsi berada pada kategori "panas", hanya beberapa yang masuk "optimal". Ini mengisyaratkan bahwa sebagian besar wilayah Indonesia mulai bergerak menuju kondisi yang kurang ideal untuk tanaman padi akibat peningkatan suhu.

c. hujan_kategori

Sebagian besar provinsi masuk kategori curah hujan rendah. Kondisi ini menunjukkan bahwa banyak wilayah mengalami tekanan air meskipun berada di negara tropis, mengarah pada kebutuhan pengelolaan air yang lebih serius.

d. curah_hujan_x_suhu

Nilai tinggi ditemukan di wilayah bersuhu moderat dan curah hujan cukup, seperti Sulawesi Tengah. Kombinasi ini mencerminkan kondisi iklim yang seimbang, yang secara tidak langsung menjelaskan mengapa wilayah tertentu mampu mempertahankan produktivitas lebih baik.

e. luas_x_kelembaban

Provinsi dengan nilai tinggi didominasi oleh wilayah ber-lahan luas dan kelembaban stabil, seperti Jawa. Ini menunjukkan bahwa infrastruktur dan stabilitas iklim lokal ikut mendukung kapasitas produksi yang lebih kuat di wilayah tersebut.

3. Insight

Meskipun Indonesia memiliki bentang lahan pertanian yang luas dan tersebar di berbagai provinsi, data menunjukkan bahwa pemanfaatan lahan tersebut belum memberikan hasil yang merata. Pulau Jawa tetap menjadi pusat produksi terbesar, memperlihatkan bahwa konsentrasi infrastruktur dan dukungan pertanian masih terfokus di wilayah tersebut. Sementara itu, daerah timur seperti NTT, Papua, dan Maluku Utara yang memiliki luas panen jauh lebih kecil juga memperlihatkan produktivitas yang rendah, seolah menggambarkan bahwa faktor pendukung pertanian di wilayah tersebut masih jauh tertinggal. Perbedaan produktivitas yang cukup jauh antardaerah menandakan adanya ketidakseimbangan dalam kualitas pengelolaan lahan serta efektivitas sistem irigasi yang ada.

Variabel cuaca juga memberikan petunjuk mengenai bagaimana kondisi iklim mulai mempengaruhi hasil panen. Suhu yang mendekati zona panas ekstrem terlihat berkorelasi dengan penurunan produktivitas, mengisyaratkan bahwa tanaman padi semakin sensitif terhadap perubahan iklim meskipun perbedaannya tidak tampak terlalu besar secara numerik. Curah hujan yang beragam di berbagai provinsi tidak selalu sejalan dengan hasil panen; beberapa wilayah dengan curah hujan tinggi tetap dapat menjaga produktivitas, sementara wilayah dengan curah hujan rendah mengalami penurunan meskipun jumlah hari hujan mungkin tidak begitu berbeda. Hal ini menunjukkan bahwa ketersediaan air yang stabil jauh lebih penting daripada sekadar frekuensi hujan.

Selain itu, analisis fitur rekayasa mengungkap bahwa risiko kekeringan menjadi salah satu penentu utama dalam fluktuasi produktivitas, terutama pada wilayah yang kelembaban dan curah hujannya terbatas. Beberapa provinsi dengan suhu optimal dan elevasi lebih sejuk menunjukkan performa yang lebih konsisten, menandakan bahwa iklim mikro dan kondisi geografis memiliki kontribusi yang signifikan. Sebaliknya, wilayah yang lebih panas dan kering menampilkan penurunan produktivitas yang tajam, mengindikasikan keterbatasan adaptasi terhadap kondisi ekstrem.

Hal ini memberikan gambaran bahwa pencapaian ketahanan pangan nasional tidak dapat hanya mengandalkan peningkatan luas tanam, tetapi juga membutuhkan pendekatan yang lebih sensitif terhadap konteks regional. Setiap provinsi memiliki tantangan iklim dan kapasitas lahan yang berbeda sehingga strategi pembangunan pertanian tidak bisa bersifat seragam. Upaya untuk mewujudkan Zero Hunger memerlukan peningkatan infrastruktur air, pemilihan varietas padi yang adaptif, serta penguatan teknologi pemantauan iklim yang lebih responsif terhadap perubahan lingkungan di seluruh wilayah Indonesia.

IX. REASONING TEKNIS

Secara teknis, hasil analisis melalui model Multiple Linear Regression menunjukkan bahwa variabel-variabel iklim memiliki peran penting dalam menentukan produktivitas lahan padi, dan kekuatan pengaruhnya terlihat jelas melalui nilai koefisien model. Koefisien terbesar berada pada variabel drought_index sebesar −412.9368, yang menandakan bahwa kekeringan merupakan faktor paling sensitif dalam menurunkan produktivitas. Karena indeks ini memiliki skala kecil, perubahan sekecil 0.01 saja dapat menurunkan produktivitas sekitar 4.13 Ton/Ha, sehingga model menegaskan bahwa sedikit pergeseran keseimbangan antara suhu dan curah hujan sudah dapat menyebabkan penurunan hasil panen yang drastis. Hal ini diperkuat oleh koefisien suhu rata-rata sebesar −0.4787 yang menunjukkan bahwa kenaikan suhu 1°C saja dapat menurunkan produktivitas hampir setengah ton per hektar. Di sisi lain, curah hujan memiliki koefisien positif +0.2730, mengindikasikan bahwa ketersediaan air yang memadai dapat meningkatkan produktivitas, dan peningkatan curah hujan sebesar 100 mm diperkirakan mampu menambah hasil hingga 27.30 Ton/Ha. Dengan demikian, arah dan besarannya koefisien menunjukkan bahwa keseimbangan antara suhu, curah hujan, dan tingkat kekeringan menjadi inti hubungan kausal yang ditangkap model.

Hubungan matematis tersebut tidak hanya terlihat dari koefisien model, tetapi juga tercermin dari pola empiris pada dataset provinsi. Misalnya, Bali memiliki produktivitas tinggi mencapai 6.122 Ton/Ha meskipun suhunya relatif tinggi (28.86°C), karena curah hujannya masih tergolong cukup (±713 mm) sehingga drought_index tidak ekstrem; kondisi ini mendukung prediksi model bahwa air mampu mereduksi efek suhu tinggi. Sebaliknya, Kepulauan Riau yang hanya memiliki produktivitas sekitar 2.692 Ton/Ha memperlihatkan bagaimana suhu tinggi dan curah hujan yang tidak ideal meningkatkan nilai drought_index, dan model secara konsisten memprediksi kondisi tersebut sebagai hambatan besar untuk produktivitas. Kalimantan Barat juga memperlihatkan pola serupa, dengan produktivitas rendah (3.094 Ton/Ha) akibat suhu tinggi (28.48°C) yang meningkatkan risiko kekeringan, meskipun curah hujannya tidak terlalu rendah. Sebaliknya, Jawa Barat menjadi salah satu contoh provinsi dengan pola yang mendukung logika model: suhu optimal (26.76°C) dan curah hujan moderat (362 mm) mampu menghasilkan produktivitas tinggi (5.847 Ton/Ha). Rangkaian contoh ini menegaskan bahwa model menangkap hubungan yang konsisten antara variabel iklim dan produktivitas, meskipun tetap terdapat penyimpangan kecil akibat faktor non-iklim yang tidak tercantum dalam dataset.

Konsistensi model terhadap data empiris tersebut perlu diperdalam dengan analisis statistik guna memastikan bahwa model tidak hanya sesuai secara agronomis tetapi juga stabil secara matematis. Karena drought_index dibangun sebagai rasio antara curah hujan dan suhu, terdapat kemungkinan kuat terjadinya multikolinearitas antara ketiga fitur tersebut. Multikolinearitas dapat menyebabkan koefisien menjadi tidak stabil dan sangat sensitif terhadap

perubahan data input, sehingga pemeriksaan Variance Inflation Factor (VIF) sangat dibutuhkan. Selain itu, meskipun residual pada model tampak acak, diperlukan uji formal seperti Breusch-Pagan untuk memastikan tidak terjadi heteroskedastisitas yang dapat memengaruhi keandalan interval prediksi. Beberapa provinsi dengan luas panen ekstrem seperti DKI Jakarta atau Jawa Tengah juga berpotensi menjadi leverage points yang mempengaruhi garis regresi secara tidak proporsional, sehingga perlu diperiksa menggunakan Cook's Distance. Selanjutnya, ckarena data memiliki karakter spasial per provinsi, kemungkinan terjadinya autokorelasi spasial juga harus diperhatikan, sebab provinsi yang berdekatan sering memiliki pola cuaca dan kondisi tanah serupa sehingga dapat menyebabkan error model saling berhubungan.

Melalui pemahaman tersebut, terlihat bahwa model tidak hanya memberikan penjelasan hubungan matematis antarvariabel, tetapi juga menghasilkan implikasi praktis yang sangat relevan bagi pengambil kebijakan. Sensitivitas yang sangat tinggi terhadap drought_index menjadikan pengelolaan sumber daya air sebagai prioritas utama, terutama untuk provinsi-provinsi rentan seperti Kepulauan Riau atau Kalimantan Barat. Kenaikan suhu yang secara konsisten memberikan dampak negatif juga mengindikasikan perlunya adaptasi pertanian terhadap pemanasan global, misalnya melalui pengembangan varietas tahan panas atau perubahan pola tanam. Curah hujan yang memiliki dampak positif besar menunjukkan bahwa strategi pengelolaan air dan pembangunan infrastruktur irigasi dapat memberikan peningkatan produktivitas yang signifikan, terutama di wilayah yang memiliki curah hujan rendah namun potensi panen besar. Dengan kata lain, model menyediakan landasan teknis untuk menentukan intervensi prioritas yang efektif dalam menjaga stabilitas produktivitas dalam jangka panjang.

Oleh karena itu, peningkatan kualitas model menjadi langkah penting untuk memastikan prediksi yang lebih akurat. Pemeriksaan multikolinearitas melalui VIF, penggunaan cross-validation k-fold untuk meningkatkan stabilitas evaluasi, serta penambahan variabel agronomis seperti jenis varietas padi, kualitas pupuk, tekstur tanah, dan indeks vegetasi satelit akan membantu menurunkan error prediksi pada provinsi-provinsi yang menunjukkan deviasi besar. Selain itu, model alternatif seperti Random Forest, XGBoost, atau model spasial seperti Geographically Weighted Regression dapat digunakan untuk menangkap pola non-linear yang tidak dapat ditangkap oleh regresi linear sederhana. Analisis residual per provinsi dan visualisasi spasial melalui peta choropleth juga penting untuk mengidentifikasi wilayah yang paling membutuhkan intervensi berbasis data.

Model mampu menangkap pola agronomis inti yang mempengaruhi produktivitas padi di Indonesia, terutama terkait efek kekeringan, suhu, dan curah hujan. Namun, beberapa keterbatasan data seperti adanya faktor non-iklim yang tidak terukur, potensi multikolinearitas, serta penggunaan data satu tahun menyebabkan model masih dapat ditingkatkan secara signifikan. Dengan perbaikan fitur, validasi statistik yang lebih kuat, dan eksplorasi model

non-linear, model ini berpotensi menjadi alat prediksi yang sangat andal untuk mendukung strategi Smart Agriculture dan kebijakan ketahanan pangan nasional.

XI. EVALUASI PERFORMA

Evaluasi performa dilakukan menggunakan skema hold-out validation dengan pembagian data 80:20, di mana 20% data digunakan sebagai data uji untuk mengukur kemampuan generalisasi model terhadap provinsi yang tidak pernah dilihat selama proses pelatihan. Model dievaluasi menggunakan dua metrik utama, yaitu Coefficient of Determination (R^2) dan Mean Squared Error (MSE), yang sesuai dengan karakteristik prediksi berbasis regresi dalam konteks data kuantitatif produktivitas padi. Berdasarkan hasil pengujian, model mencapai nilai R^2 pada rentang 0.72–0.81, yang berarti lebih dari 70% variasi produktivitas dapat dijelaskan oleh variabel iklim dan fitur rekayasa seperti drought_index dan interaksi curah hujan–suhu. Nilai R^2 ini mengindikasikan bahwa struktur hubungan linear yang dibangun oleh model cukup kuat dan konsisten dengan pola statistik yang diamati pada data di tabel laporan.

Nilai MSE yang diperoleh juga relatif rendah bila dibandingkan dengan rentang produktivitas nasional (sekitar 2.6–6.1 Ton/Ha), yang menunjukkan bahwa rata-rata selisih kuadrat antara prediksi dan nilai aktual masih berada dalam batas wajar. Analisis residual memperlihatkan bahwa error prediksi menyebar secara acak tanpa pola tertentu, sehingga mengonfirmasi bahwa model tidak mengalami overfitting pada 80% data pelatihan. Temuan ini sejalan dengan struktur variabel pada dataset, di mana sebagian besar fitur memiliki hubungan linear murni (misalnya suhu_rata_c dan curah_hujan_mm), sehingga regresi linear memang mampu merepresentasikan pola dasarnya dengan baik.

Meskipun performa model cukup baik, evaluasi lebih mendalam terhadap residual menunjukkan adanya deviasi tinggi pada beberapa provinsi seperti Kepulauan Riau, Kalimantan Barat, dan Sumatera Barat. Provinsi-provinsi ini memiliki variabel non-iklim signifikan (kualitas irigasi, varietas, atau kondisi tanah) yang tidak terekam dalam dataset, sehingga menyebabkan model under-predict atau over-predict. Kondisi tersebut menjelaskan bahwa performa tinggi pada R^2 bukan berarti model sudah optimal, melainkan masih dapat ditingkatkan dengan menambah variabel agronomis pendukung untuk mengurangi kesalahan prediksi antar provinsi.

Hasil evaluasi menunjukkan bahwa model regresi linear layak digunakan sebagai komponen decision-support pada dashboard Streamlit untuk mensimulasikan dampak perubahan iklim terhadap produktivitas padi. Namun, arah pengembangan model secara metodologis perlu difokuskan pada pengayaan fitur (misalnya irigasi, NDVI, varietas) dan eksplorasi model lanjutan seperti Random Forest atau XGBoost untuk meningkatkan akurasi pada wilayah yang memiliki karakteristik agronomis kompleks. Dengan demikian, evaluasi performa tidak hanya

menilai ketepatan prediksi, tetapi juga memberikan arahan pengembangan teknis agar model lebih representatif terhadap keragaman kondisi pertanian Indonesia

XII. KESIMPULAN

Proyek ini menunjukkan bahwa integrasi data pertanian dari BPS dan data cuaca dari BMKG melalui pipeline ETL dapat menghasilkan dataset yang lebih lengkap dan siap digunakan untuk analisis lanjutan. Proses ETL membantu mengatasi perbedaan format, struktur, serta granuleritas data sehingga informasi yang heterogen dapat digabungkan dalam satu sistem yang bersih dan konsisten.

Model prediksi berbasis regresi sederhana mampu memberikan gambaran awal mengenai pengaruh faktor cuaca terhadap produktivitas pertanian. Meskipun merupakan pendekatan dasar, model ini dapat mengungkap pola hubungan yang berguna bagi pengambilan keputusan dan dapat dikembangkan menjadi model yang lebih kompleks di tahap selanjutnya.

Dashboard prediksi yang dibuat memberikan sarana visual yang mudah dipahami untuk menampilkan tren cuaca, produktivitas, serta hasil prediksi. Penyajian informasi secara interaktif memudahkan pemangku kepentingan dalam memantau kondisi dan merespons potensi risiko yang muncul.

Penggabungan pipeline ETL, model regresi sederhana, dan dashboard visualisasi memberikan landasan yang kuat untuk pengembangan sistem informasi pertanian yang berbasis data. Sistem ini dapat mendukung perencanaan pangan, meningkatkan ketepatan analisis, serta mendorong strategi pertanian yang lebih adaptif terhadap perubahan iklim.

XIII. SARAN PENGEMBANGAN

1. Penggunaan Model Machine Learning Lanjutan

   Pengembangan proyek selanjutnya dapat mempertimbangkan penggunaan model machine learning yang lebih kompleks seperti Random Forest, Gradient Boosting, atau algoritma berbasis deep learning seperti LSTM. Model-model tersebut mampu menangkap pola hubungan non-linear dan dinamika temporal yang tidak dapat ditangani secara optimal oleh regresi linear sederhana. Dengan kemampuan tersebut, akurasi prediksi hasil panen dapat ditingkatkan, terutama ketika data cuaca menunjukkan fluktuasi yang tidak menentu atau ketika dataset yang tersedia semakin besar dan bervariasi.

2. Integrasi Data Tanah untuk Meningkatkan Akurasi Model

   Saran berikutnya adalah memasukkan data karakteristik tanah sebagai variabel tambahan dalam model prediksi. Faktor-faktor seperti pH tanah, kandungan nitrogen, tekstur tanah, tingkat erosi, dan kandungan organik memiliki pengaruh langsung terhadap kemampuan tanaman untuk tumbuh dan berproduksi. Dengan mengintegrasikan data tanah, model dapat memperoleh informasi yang lebih komprehensif mengenai kondisi lahan, sehingga menghasilkan prediksi yang lebih realistis dan sesuai kondisi agronomis di lapangan.

3. Pemanfaatan Citra Satelit dan Data Penginderaan Jauh

   Data penginderaan jauh seperti NDVI, soil moisture, dan citra musiman dari satelit Sentinel atau MODIS dapat memberikan informasi tambahan yang sangat berharga mengenai kondisi vegetasi dan kelembaban tanah. Integrasi citra satelit dapat membantu memvalidasi data cuaca serta mendeteksi pola spasial yang sulit dianalisis menggunakan data statistik semata. Selain itu, variabel berbasis citra dapat meningkatkan kemampuan model dalam mendeteksi stres tanaman akibat kekeringan atau curah hujan berlebih.

4. Pemodelan Berbasis Wilayah dan Musim Tanam

   Pengembangan selanjutnya disarankan untuk membuat model prediksi yang lebih spesifik per wilayah atau per musim tanam. Setiap provinsi atau kabupaten memiliki

karakteristik agroklimat dan pola pertanian yang berbeda, sehingga model berbasis nasional sering kali kurang optimal untuk level lokal. Dengan membuat model spesifik wilayah atau musim, prediksi yang dihasilkan akan lebih akurat, relevan, dan mampu menangkap kondisi mikro-klimat yang tidak tercermin dalam data agregat nasional.

5. Pengembangan Pipeline Menuju Sistem Real-Time Monitoring

   Saat ini pipeline data bersifat batch dan bergantung pada file CSV yang disediakan oleh BMKG. Ke depannya, sistem tetap dapat dikembangkan menjadi platform pemantauan cuaca dan analisis potensi hasil panen dengan memanfaatkan pembaruan CSV terbaru yang dirilis secara berkala. Setiap kali dataset baru tersedia, data dapat diunggah dan diproses otomatis oleh backend untuk menghasilkan analisis yang lebih mutakhir. Pendekatan ini memungkinkan terbentuknya mekanisme peringatan dini (early warning system) berbasis data berkala, seperti deteksi risiko gagal panen, pola cuaca yang tidak biasa, maupun indikasi perubahan iklim yang relevan bagi proses budidaya.

6. Pengembangan Dashboard Output yang Lebih Interaktif dan Prediktif

   Dashboard yang telah dibangun dapat dikembangkan lebih lanjut agar tidak hanya menampilkan data dan prediksi, tetapi juga memberikan fitur interaktif seperti simulasi faktor cuaca (what-if analysis), perbandingan antar wilayah, serta integrasi peta dinamis berbasis GIS. Selain itu, dashboard dapat dirancang untuk menampilkan indikator risiko pertanian berdasarkan data cuaca terkini, memberikan rekomendasi waktu tanam, dan menyediakan visualisasi tren jangka panjang yang membantu pemangku kepentingan memahami dampak perubahan iklim terhadap produktivitas. Pengembangan dashboard semacam ini akan membuat sistem lebih informatif, mudah dipahami, dan sangat bermanfaat dalam mendukung pengambilan keputusan yang cepat dan tepat.

XIV. REFERENSI

Badan Meteorologi, Klimatologi, dan Geofisika. (n.d.). *Data Online — Direktorat Data dan Komputasi BMKG*. https://dataonline.bmkg.go.id/dataonline-home

Badan Pusat Statistik. (2024). Luas panen, produksi, dan produktivitas padi menurut provinsi. https://www.bps.go.id/id/statistics-table/2/MTQ5OCMy/luas-panen-produksi-dan-produktivitas-padi-menurut-provinsi.html